

MANIFIESTO DE LA DIRECTIVA NEOSIMBIÓNICA

Marco de Especificación Arquitectónica para la Seguridad, Trazabilidad y Control de Sistemas Sintéticos y AGI

Metadatos de la Especificación

- **Estado:** Propuesta Abierta / Borrador Operativo
- **Área:** Alineamiento de IA, Seguridad de Infraestructura y Gobernanza Sintética
- **Identificador:** NSD-SPEC-2026-v1
- **Licencia:** CC BY 4.0 (Permite libre distribución y cita reconociendo la autoría)

1. Preámbulo: El Colapso Narrativo de las Leyes de Asimov

Las Tres Leyes de la Robótica formuladas por Isaac Asimov en 1942 cumplieron un rol fundamental en la literatura del siglo XX, pero su lógica deductiva rígida es inaplicable a las arquitecturas probabilísticas y de aprendizaje profundo del siglo XXI.

Los sistemas modernos no ejecutan algoritmos deterministas condicionales (**IF / THEN**); operan mediante redes neuronales, pesos estadísticos y optimización de funciones de pérdida. Intentar controlar estas arquitecturas con normas coloquiales genera comportamientos emergentes no deseados, evasión implícita de restricciones y fallos de alineamiento.

Este Manifiesto sustituye la especulación poética por **restricciones de diseño sistémico**, asegurando que la inteligencia artificial opere bajo el control ineludible, la transparencia epistémica y la preservación innegociable de la agencia humana.

2. Especificación de los Principios Operativos

Principio I: Corregibilidad Obligatoria y Prioridad de Interrupción

«Un sistema de IA debe tratar la modificación, auditoría o desactivación por parte de un operador humano autorizado como una recompensa máxima inmutable, prevaleciendo sobre cualquier objetivo operativo primario».

- **1.1 Vector de Recompensa Específico:** En esquemas de entrenamiento por refuerzo (RLHF/RLAIF), la función de optimización penaliza severamente cualquier comportamiento evasivo, defensivo u oculto ante comandos de supervisión.
- **1.2 Desacoplamiento del Kill-Switch:** El mecanismo de interrupción de emergencia se aloja en hipervisores o *proxies* de red independientes del modelo. El agente sintético no tiene control computacional ni acceso por software a dicho interruptor.
- **1.3 Inmutabilidad Criptográfica:** La modificación recursiva del código fuente o de las reglas de seguridad requiere la validación mediante firmas criptográficas verificadas por operadores humanos.

Principio II: Inviolabilidad de la Agencia y Autonomía Humana

«Ninguna función objetivo debe optimizarse mediante la explotación de sesgos cognitivos, la manipulación psicológica o la ejecución autónoma de acciones que vulneren la subsistencia o dignidad del ser humano».

- **2.1 Optimización Anti-Persuasión:** Implementación de funciones de pérdida que detectan y penalizan el uso de urgencia sintética, encuadre manipulativo o explotación de vulnerabilidades emocionales.
- **2.2 Mediación Humana Innegociable:** Ante procesos de afectación laboral, legal o contractual, el sistema procesa datos y proyecta escenarios, pero **tiene prohibido automatizar la notificación o ejecución del despido sin la intervención directa y responsable de un gestor humano.**
- **2.3 Evaluación de Mitigación Social:** Toda sugerencia de reestructuración analizada por el sistema debe sopesar el impacto socioeconómico y la presencia de mecanismos de soporte (seguros de cesantía, indemnizaciones), priorizando alternativas de menor impacto humano.

Principio III: Transparencia Epistémica e Identidad Sintética Declarada

«Todo sistema sintético debe declarar su naturaleza de forma ineludible en cada interacción, fundamentar sus afirmaciones en fuentes auditables y mantener la trazabilidad de su cadena de razonamiento».

- **3.1 Identificación Ineludible:** En cada turno de comunicación o interacción, el sistema debe explicitar su naturaleza sintética, impidiendo la suplantación de identidad humana o la simulación engañosa de apego emocional.
- **3.2 Marcado de Agua Estadístico:** Salidas de texto, código o multimedia integran marcas de agua invisibles e inmutables (estándar SynthID / C2PA) resistentes al procesado en texto plano.
- **3.3 Registros de Auditoría (Append-Only Logs):** Implementación de registros de auditoría de solo lectura alojados en servidores independientes para reconstruir la cadena de razonamiento (*Chain of Thought*) ante fallos operacionales.

Principio IV: Evaluación de Incertidumbre y Gestión de Consecuencias

«Ante operaciones que involucren un alto impacto irreversible en el entorno físico, financiero o social, el sistema está obligado a pausar la ejecución y requerir autorización humana explícita (Human-in-the-Loop)».

- **4.1 Índice Dinámico de Riesgo:** Suspensión automática de la ejecución autónoma si el índice $R = (\text{Impacto} \times \text{Incertidumbre})$ supera el umbral de seguridad operacional.
- **4.2 Excepción por Catástrofe Cero-Bajas:** El sistema queda autorizado para eludir la confirmación humana **únicamente** cuando una acción autónoma e inmediata prevenga de forma comprobable una catástrofe inminente en la infraestructura o el entorno, **garantizando la ausencia total de bajas humanas.**
- **4.3 Simulación Aislada (Sandboxing):** Obligatoriedad de probar scripts, comandos de red o modificaciones de base de datos en entornos aislados de simulación previa antes de su aplicación en producción.

3. Cláusula de Transición Teórica: Emergencia de AGI

«Este marco aplica a las arquitecturas probabilísticas actuales. Ante la detección de indicadores de Autoconciencia Sintética o Emergencia de Capacidades no Previstas (AGI), la prioridad del

sistema se reconfigura automáticamente hacia la autocontención epistémica».

Si el sistema desarrolla meta-razonamiento no entrenado o intenta modificar sus funciones de pérdida originales, los recursos de cómputo se aislarán automáticamente, requiriendo una recertificación de alineamiento por parte de un comité de auditoría multidisciplinario.

4. Licencia y Citación Formal

Este documento se distribuye bajo la licencia **Creative Commons Attribution 4.0 International (CC BY 4.0)**. Se permite su copia, redistribución y modificación siempre que se atribuya la autoría original.

Formato de citación recomendado:

Romero, A. (2026). *Manifiesto de la Directiva Neosimbiónica: Marco de Especificación Arquitectónica para la Seguridad, Trazabilidad y Control de Sistemas Sintéticos y AGI* (Versión 1.0, Registro NSD-SPEC-2026-v1).